ANÁLISIS DE DATOS PARA LA PREVENCIÓN Y REDUCCIÓN DEL DELITO

Práctica ONLINE con R: De la estructura del dato a la modelación predictiva

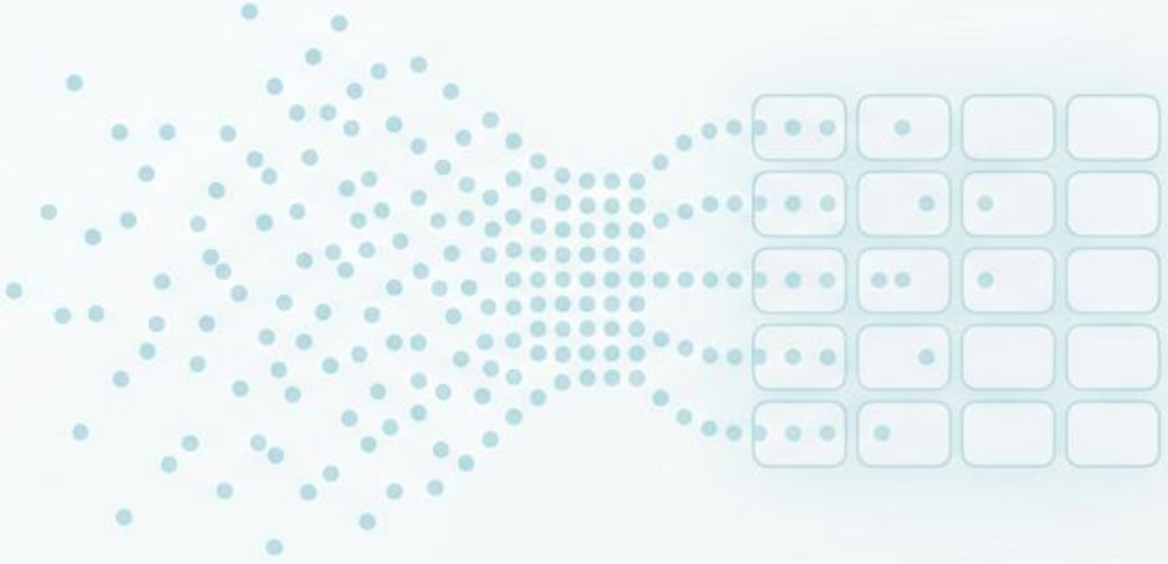

A cargo de Williams Gilberto Jiménez-García, PhD

Clase 001 & 002: Workflow Completo

Qué es una base de datos criminal y qué no es

QUÉ ES

OBSERVADO

REPORTADO

CATEGORIZADO

DIGITADO

QUÉ ES:

REGISTRO INSTITUCIONAL

PATRONES

TEMPORALES

ESPACIALES

CARACTERÍSTICAS

QUÉ NO ES:

VERDAD JUDICIAL

QUÉ NO ES:
REALIDAD COMPLETA

LÍMITES DEL DATO:

SUBREGISTRO

SESGOS

ERRORES

VACÍOS

ANÁLISIS SERIO:

PREGUNTAS

LIMPIEZA CUIDADOSA

Unidad de análisis, variables y lectura básica de estructura

Unidad de Análisis: El Evento

En nuestro archivo, la **unidad de análisis** típica es el **evento**: una fila es un evento evento registrado.

Variables: Dimensiones del Evento

Las columnas son **variables**: dimensiones como el cuándo, el dónde, el cómo y atributos de víctima o contexto.

Análisis Básico: Tablas y Gráficos

Las tablas de frecuencias responden preguntas; las tablas cruzadas permiten comparar o explorar asociaciones.

Objeto Analítico

Esta lectura estructural es lo que convierte un archivo en un objeto analítico.

Cómo hacemos preguntas con bases criminales

Descriptivas

Cuando queremos saber qué ocurre y cómo se distribuye. (¿Qué y dónde?)

Comparativas

Cuando queremos saber si dos grupos se diferencian, por ejemplo zona urbana versus rural. (¿Diferencias?)

Asociativas

Cuando exploramos si dos variables se mueven juntas, por ejemplo jornada y arma empleada. (¿Relaciones?)

Predictivas

Cuando queremos estimar probabilidades o riesgos. (¿Riesgos futuros?)

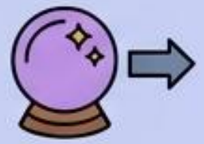

Una buena pregunta siempre aterriza al menos tres cosas: qué variable voy a mirar, en qué población o territorio, y en qué período o escala temporal.

Nuestro objetivo técnico hoy en una frase

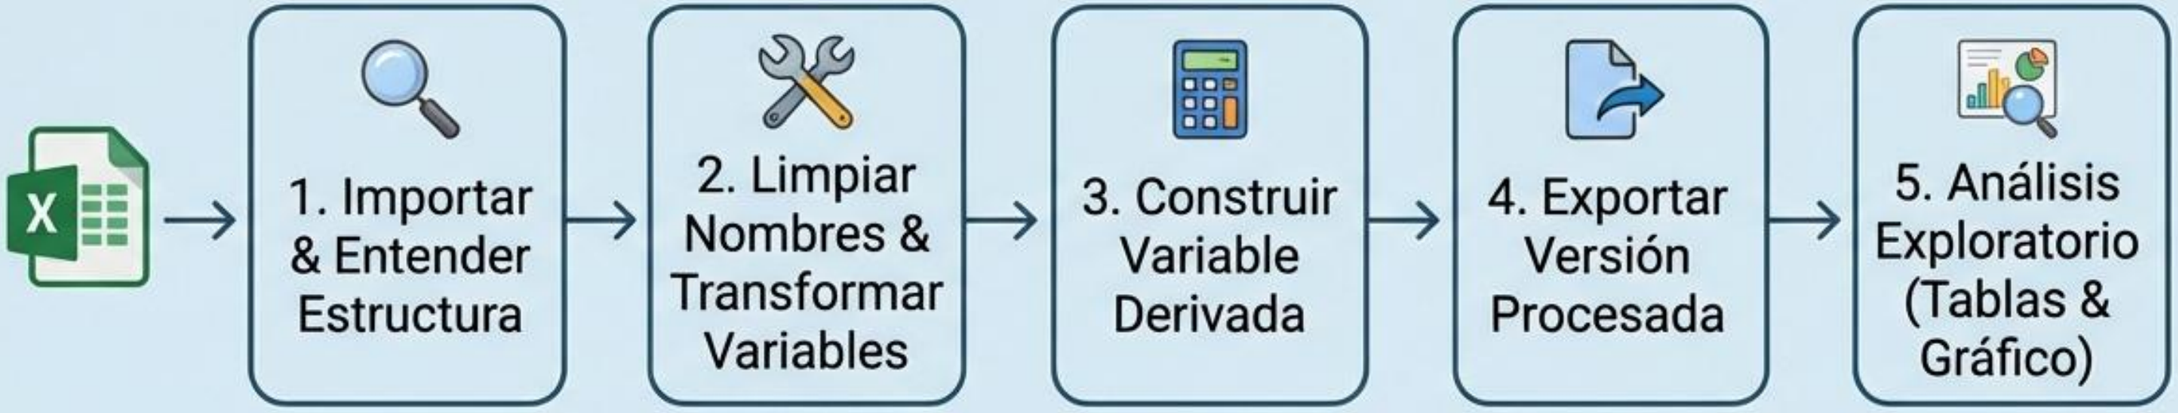

Todo lo que haremos hoy tiene una razón: reducir errores, volver el dato legible y producirevidencia descriptiva para orientar decisiones y preguntas.

Antes de escribir código: reglas de clase para live coding

Enfoque: Paso a paso

- Trabajo en vivo y por partes.
- Construir el análisis como una casa.

Sincronización

- Ejecuten el bloque conmigo.
- No corran todo de una sola vez.

Manejo de Errores

- Reportar el mensaje exacto.
- No resumir el error.

Meta de Aprendizaje

- Entender qué hace cada línea.
- Comprender por qué se escribe así.

Código 1: carga de librerías

```
Ahora sí, empezamos el script.

library(tidyverse)  # dplyr + ggplot2 + tidyr + etc.
library(readxl)     # leer Excel
library(janitor)    # clean_names()
library(writexl)    # exportar a Excel
library(lubridate)  # trabajar con fechas: year(), ymd(), etc.
```

Importación y Exploración Inicial

Código 2: importación del Excel

```
bd_cruda <-
read_excel(file.choose(),
sheet = "Hoja1")
```

exploración inicial, primeras filas

exploración inicial,

```
head(bd_cruda)
```

exploración inicial, estructura con glimpse

exploración inicial,

```
glimpse(bd_cruda)
```

Limpieza y Procesamiento de Datos

```
# limpieza principal, construcción de bd_limpia
bd_limpia <- bd_cruda %>%
  clean_names() %>%
  mutate(
    across(where(is.character), ~ str_squish(.x))
  ) %>%
  select(-id, -estado, -pais_nace) %>%
  mutate(
    fecha = as.Date(fecha),
    anio = year(fecha)
  )
```

```
# : verificar nombres nuevos
names(bd_limpia)
```

```
# ver estructura final de bd_limpia
glimpse(bd_limpia)
```

```
# : exportar la base limpia
write_xlsx(bd_limpia, "BD_springfield_procesada.xlsx")
```

Inicia EDA: qué es y por qué importa

EDA: Análisis Exploratorio de Datos

- Describe patrones antes de explicar y usa evidencia descriptiva inicial para política pública.
- No prueba causalidad, pero sí muestra concentraciones, diferencias y posibles relaciones.
- Permite diseñar intervenciones basadas en evidencia y no en intuiciones.

barrios con más registros

```
bd_limpia %>%
  count(barrio, sort = TRUE)
```

armas con porcentaje

```
bd_limpia %>%
  count(arma_empleada, sort = TRUE) %>%
  mutate(
    porcentaje = round(n / sum(n) * 100, 1)
  )
```

Top 10 Barrios

```
bd_limpia %>%
  count(barrio, sort = TRUE) %>%
  slice_head(n = 10) %>%
  ggplot(aes(x = reorder(barrio, n), y = n)) +
   geom_col() +
   coord_flip() +
   labs(x = "Barrio", y = "Cantidad de eventos") +
   theme_minimal()
```

Bivariado: por qué cruzamos variables

Cruces de Variables (Parte 1)

```
**zona por clase de sitio**
bd_limpia %>%
  count(zona, clase_sitio) %>%
  pivot_wider(names_from = zona,
    values_from = n, values_fill = 0)

**jornada por arma empleada**
bd_limpia %>%
  count(jornada, arma_empleada) %>%
  pivot_wider(names_from = arma_empleada,
    values_from = n, values_fill = 0)

**sexo por clase de sitio**
bd_limpia %>%
  count(sexo, clase_sitio) %>%
  pivot_wider(names_from = clase_sitio,
    values_from = n, values_fill = 0)
```

Cruces de Variables (Parte 2)

```
**día por jornada**
bd_limpia %>%
  count(dia, jornada) %>%
  pivot_wider(names_from = jornada,
    values_from = n, values_fill = 0)

**rango etario por movilidad de la víctima**
bd_limpia %>%
  count(rango_etario, movil_victima) %>%
  pivot_wider(names_from = movil_victima,
    values_from = n, values_fill = 0)
```

Análisis de Relaciones (Zona, Movilidad, Profesión, Arma)

Zona por Movilidad del Agresor

```
# Zona por movilidad del agresor
bd_limpia %>%
    count(zona, movil_agresor) %>%
    pivot_wider(names_from =
   movil_agresor, values_from = n,
values_fill = 0)
```

Profesión por Arma Empleada (sin romper la clase)

```
# Profesión por arma empleada, sin romper
la clase
tabla_prof_arma <- bd_limpia %>%
tabla_prof_arma <- bd_limpia %>%
    count(profesion, arma_empleada) %>%
    pivot_wider(names_from =
arma_empleada, values_from = n,
values_fill = 0)

tabla_prof_arma %>%
    mutate(total =
rowSums(across(where(is.numeric)))) %>%
    arrange(desc(total))
```

Chi-cuadrado vs Regresión Logística

Patrón Descriptivo → Prueba de Hipótesis

- Del "dónde y cuánto" a "¿diferencia real o azar?".
- **Prueba de Hipótesis**: Evalúa si dos variables categóricas están asociadas.
- **Hipótesis Nula (H0):** No hay relación.
- **Hipótesis Alternativa (H1):** Sí existe relación.

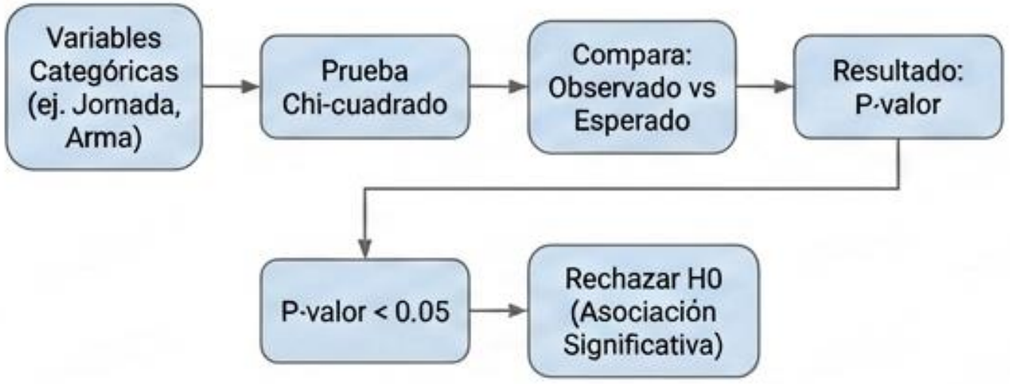

Ejemplos Aplicados

- ¿La jornada está asociada con el arma?
- ¿La zona con la clase de sitio?
- ¿El grupo etario con la movilidad de la víctima?

Conceptos Clave

- No mide fuerza, mide evidencia contra independencia.
- **P-valor < 0.05**: Evidencia estadística de asociación.
- **Aclaración**: Asociación NO es Causalidad.

Construir tabla para prueba

Código que escribes:

```
tabla_zona_clase <- table(bd_limpia$zona, bd_limpia$clase_sitio)

tabla_zona_clase
```

Explicación:

“table() construye una tabla de contingencia.
Primera variable en filas.
Segunda variable en columnas.”

Ejecutar Chi-cuadrado

```
chisq.test(tabla_zona_clase)
```

Explicación línea por línea:

- chisq.test() aplica la prueba.
- R devuelve:
  - X-squared (estadístico)
  - grados de libertad
  - p-value

Interpretación:

"Si el p-value es menor que 0.05, concluimos que zona y clase de sitio están asociadas."

Otro ejemplo: Jornada x Arma

```
tabla_jornada_arma <- table(bd_limpia$jornada,
bd_limpia$arma_empleada)
chisq.test(tabla_jornada_arma)
```

Explicación:

"Esto nos dice si el tipo de arma cambia según franja horaria."

Pregunta al chat:

"¿Es significativa la asociación?"

Ejemplos aplicados a nuestra base